



自動化資料工程與爬蟲系統

實習成果發表
陳子齊 (統計研究所)

Orange Electronic 橙的電子

大綱

網路爬蟲介紹

Interpneu爬蟲運作架構 / 使用流程 / 結果

AutoBild 爬蟲運作架構 / 使用流程 / 結果

GitHub雲端自動抓取存儲 / 使用方法

Partslink24爬蟲初步流程圖

技術問題與改進方案

網路爬蟲的運作原理

一個完整的爬蟲系統，運作生命週期通常包含四個階段：

發送請求 (Request) → 獲取回應 (Response) → 解析萃取 (Parse & Extract) → 資料儲存 (Store)

1. 靜態爬蟲與 API 攔截 (Protocol-level Scraping)

- 優勢：最輕量、速度最快。
- 原理：不開啟瀏覽器，直接發送 HTTP 請求，攔截底層 HTML 或 JSON。
- 實作專案：Interpneu 爬蟲。

2. 動態渲染爬蟲 (Browser Automation)

- 場景：專解動態生成的 SPA 網頁（如 React/Vue 空殼架構）。
- 原理：啟動無頭瀏覽器，模擬真人捲動、點擊與等待等操作行為。
- 實作專案：AutoBild 爬蟲。

1. 網路爬蟲的優點

- 極致自動化與規模化
 - 將數百小時人工作業，壓縮至數十分鐘完成。
 - 結合 CI/CD (如 GitHub Actions) 實現無人值守定時更新。
- 高品質資料聚合
 - 於儲存階段直接清洗雜亂資料。
 - 運用 SQL (GROUP_CONCAT / View) 將破碎規格實時整合為乾淨關聯表。
- 突破前端介面限制
 - 無痛繞過網頁排版與隱藏限制。
 - 攔截底層 API 或解析內嵌 JSON，獲取更精確的原始數據。

2. 網路爬蟲的缺點與面臨的挑戰

- 維護成本高昂
 - 網站改版或 API 參數變更易導致腳本失效，需人工重新逆向修復。
- 嚴格的反爬蟲機制 (Anti-Scraping)
 - 連線限制：異常流量易觸發 IP 封鎖或 HTTP 429 限制。
 - 行為偵測：高防護網站 (如 Partslink24) 會檢查瀏覽器指紋與操作軌跡。
 - 應對代價：需導入動態延遲等機制，增加系統複雜度並拖慢擷取速度。
- 資料完整性與中斷風險
 - 長時間運行易受網路波動或伺服器阻擋影響導致中斷。
 - 必須實作批次寫入 (Batch Insert) 與安全退出協定 (攔截 Ctrl+C) 保障資料不遺失

Interpneu 爬蟲運作架構（靜態爬蟲與 API 攔截）



1. 智能環境自適應 (Bypass Environment Limits)

- 內建獨立 `install_requirements()` 函數，自動安裝缺失套件。
- 加入 `--break-system-packages` 機制突破系統保護，實現「一鍵啟動」。

2. 防封鎖退避策略 (Rate Limit Handling)

- 配置 `urllib3 Retry` 機制，應對伺服器異常狀態碼。
- 精準捕捉 HTTP 429 錯誤並強制冷卻，避免 IP 遭封鎖。

3. 精準 API 攔截 (Protocol-level Extraction)

- 捨棄傳統 HTML 解析，直接請求底層 API 端點。
- 結合遞迴搜尋，極速精準萃取 JSON 結構化深層數據。

4. 斷點記憶與七天週期 (Smart Resume & 7-Day Cycle)

- 即時更新進度記錄檔，實現「中斷無縫接關」。
- 內建時間戳判斷，逾期 7 天則自動清空重抓。





5. 無損覆寫與 SQL View 壓縮 (Upsert & Aggregation)

- 利用 SQLite `REPLACE INTO` 搭配多重 `UNIQUE` 鍵實現無痕去重。
- 透過 `GROUP_CONCAT` 由底層自動聚合資料，產出極淨 Excel 報表。

6. 優雅中斷安全機制 (Graceful Shutdown)

- 攔截 `Ctrl+C` 等終端機訊號，防止程式意外崩潰。
- 從容結束迴圈、強制寫入殘留資料，達成真正的「零資料遺失」。

Interpneu 爬蟲流程圖





結果

Database Structure Browse Data Edit Pragmas Execute SQL											
Table: tpms_sensors											
	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter
300	ALFA ROMEO	Giulia	2.2 Diesel	2016-01	至今	1742	AAX	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
301	ALFA ROMEO	Giulia	2.2 Diesel	2016-01	至今	1742	AAY	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
302	ALFA ROMEO	Giulia	2.2 Diesel	2016-01	至今	1742	AAY	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
303	ALFA ROMEO	Giulia	2.2 Diesel 4WD	2016-01	至今	1742	ABI	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
304	ALFA ROMEO	Giulia	2.2 Diesel 4WD	2016-01	至今	1742	ABI	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
305	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir Q4	2021-01	至今	1742	ACI	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
306	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir Q4	2021-01	至今	1742	ACI	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
307	ALFA ROMEO	Giulia Quadrifoglio	GTA	2021-01	2021-01	1742	ACH	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
308	ALFA ROMEO	Giulia Quadrifoglio	GTA	2021-01	2021-01	1742	ACH	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
309	ALFA ROMEO	Giulia Quadrifoglio	GTAm	2021-01	2021-01	1742	ACH	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
310	ALFA ROMEO	Giulia Quadrifoglio	GTAm	2021-01	2021-01	1742	ACH	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
311	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir	2020-01	至今	1742	ACF	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
312	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir	2020-01	至今	1742	ACF	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
313	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir	2019-01	至今	1742	ACA	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
314	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir	2019-01	至今	1742	ACA	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
315	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir	2018-01	至今	1742	ABP	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
316	ALFA ROMEO	Giulia Quadrifoglio	2.0 Turbo MultiAir	2018-01	至今	1742	ABP	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
317	ALFA ROMEO	Giulia Quadrifoglio	2.2 Diesel	2018-01	至今	1742	ABY	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
318	ALFA ROMEO	Giulia Quadrifoglio	2.2 Diesel	2018-01	至今	1742	ABY	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433
319	ALFA ROMEO	Giulia Quadrifoglio	2.2 Diesel	2018-01	至今	1742	ABX	05/2016 -	TG1D 2910000063300 (Ident: A2C9915450180)	VDO	433
320	ALFA ROMEO	Giulia Quadrifoglio	2.2 Diesel	2018-01	至今	1742	ABX	05/2016 -	TG1C A2C9714580280 (Ident: 2910000195900)	VDO	433

AutoBild 爬蟲運作架構（動態渲染）

1. 非同步無頭瀏覽器 (Playwright)

- 啟動 Chromium，模擬真實用戶的 User-Agent 與視窗環境。

2. 自動突破 Cookie 彈窗

- 精準定位 iframe 並模擬點擊同意，解決傳統爬蟲卡死問題。

3. 觸發延遲載入 (Lazy Loading)

- 透過自動捲動 (window.scrollTo)，強制網頁渲染尚未載入的動態資料。


4. 模擬真人 DOM 操作

- 自動點擊介面按鈕，暴力展開並解鎖所有隱藏的車系與車款變體。

5. 精準攔截動態 API (核心技術)

- 設置背景監聽器 (context.on)，直接攔截含有 HSN/TSN 的 JSON 回應。
- 直接獲取乾淨數據，徹底取代低效的 HTML 原始碼解析。


AutoBild 爬蟲流程圖



結果



Database Structure Browse Data Edit P								
Table: car_catalog Filter in any column								
	Brand	Model	Category	Fuel_Type	Typ	Start_Year	End_Year	HSN_TSN
	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter
1	XPENG	P7Plus	高背掀背車	電力	P7+ AWD Performance seit 01/2026	2026	至今	N/A
2	XPENG	P7Plus	高背掀背車	電力	P7+ RWD Long Range seit 01/2026	2026	至今	N/A
3	XPENG	P7Plus	高背掀背車	電力	P7+ RWD Standard Range seit 01/2026	2026	至今	N/A
4	WIESMANN	Wiesmann Gt Mf4	雙門跑車	汽油	GT MF4	2003	2015	N/A
5	WIESMANN	Wiesmann Gt Mf4	雙門跑車	汽油	GT MF4 SMG	2003	2015	N/A
6	WIESMANN	Wiesmann Roadster Mf3	敞篷跑車	汽油	Roadster MF3	1993	2011	N/A
7	WIESMANN	Wiesmann Roadster Mf4	敞篷跑車	汽油	Roadster MF4	2010	2015	N/A
8	WIESMANN	Wiesmann Roadster Mf4	敞篷跑車	汽油	Roadster MF4 Sportautomatik	2010	2015	N/A
9	WIESMANN	Wiesmann Roadster Mf4	敞篷跑車	汽油	Roadster MF4-S	2010	2015	N/A
10	WIESMANN	Wiesmann Roadster Mf4	敞篷跑車	汽油	Roadster MF4-S DKG	2010	2015	N/A
11	WIESMANN	Wiesmann Roadster Mf5	敞篷跑車	汽油	Roadster MF5 SMG	2010	2015	N/A
12	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI	2010	至今	N/A
13	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI, Advantage	2010	至今	N/A
14	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI, Atacama	2010	至今	N/A
15	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI, Dark Label	2010	至今	N/A
16	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI, Highline	2010	至今	N/A
17	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI, Trendline	2010	至今	N/A
18	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI, Ultimate	2010	至今	N/A
19	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI 4MOTION	2010	至今	N/A
20	VW	Amarok	皮卡	柴油	Amarok 2.0 BiTDI 4MOTION, Advantage	2010	至今	N/A



雲端自動化爬蟲：GitHub 部署



本地到雲端的進化：將 Interpneu 與 AutoBild 專案遷移至 GitHub (OrangeInterpneu, OrangeAutobild)

1. CI/CD 雲端自動化 (無人值守排程)



- 編寫 YAML 建立 GitHub Actions，透過 cron 排程定時觸發爬蟲。
- 運行於雲端虛擬伺服器，徹底擺脫本地硬體與關機限制。

2. 資料存取與成果交付


- Artifacts 打包下載：自動打包 SQLite 與 Excel 報表，網頁端一鍵下載 ZIP。
- Auto-Commit 同步：由 GitHub Bot 自動 Push，將最新資料庫與進度檔同步至版本庫。

3. 專案 Repository

- OrangeInterpneu：<https://github.com/chi71211/OrangeInterpneu>
- OrangeAutobild：<https://github.com/chi71211/OrangeAutobild>



Partslink24爬蟲初步流程圖



Partslink24爬蟲技術問題



1. 語言不通與關鍵字碎片化

- 德語環境辨識障礙。
- TPMS 術語缺乏統一 (如 BMW: RDC, VAG: Sensor für Reifendruck)。
- 必須針對各車廠建立專屬的檢索邏輯。

2. 動態渲染與前端防護

- 基於 React 的 SPA 架構，傳統靜態爬蟲完全失效。
- 嚴密 Cookie 彈窗阻擋，需實作 Shadow DOM 穿透與強制移除。

3. 異構目錄與搜尋限制

- 目錄結構碎裂：各車廠導覽邏輯各異 (BMW 表格定位、VAG 層級點擊)。
- 搜尋框動態隱藏：特定層級強迫隱藏搜尋框 (width=0)，常規搜尋失效。

4. 資料解析與雜訊過濾

- 假陽性干擾：零件號易與銘牌混淆，需導入嚴格正則表達式與排除清單。
- 無實體零件：部分車型採「間接式 TPMS」(ABS運算)，無實體零件易致誤判。

5. 長時間運行穩定性

- Playwright 長時運行易引發 EPIPE 崩潰。
- 必須設計容錯重啟與進度斷點機制，保障系統穩定。

Partslink24爬蟲改進方案



1. 建立「關鍵字資料庫」(Keyword Mapping)
 - 利用獨立 JSON 或 SQLite 定義各品牌專屬檢索規則。
 - 設定正負向表列（例：BMW 鎖定 433MHz，排除 Steuergerät）。
 - 效益：分離主程式與搜尋邏輯，大幅提升擴充性。
2. 無頭瀏覽器與隱身防護 (Stealth Mode)
 - 導入 Playwright 進行網頁動態操作。
 - 抹除 WebDriver 指紋並偽裝真實 User-Agent。
 - 效益：有效規避網站 IP 封鎖與自動化偵測。
3. API 攔截取代 DOM 解析 (效能突破)
 - 放棄緩慢的網頁元素搜尋，攔截底層 REST API 回應。
 - 直接獲取結構化 JSON，免去複雜的正則提取。
 - 效益：執行速度較常規搜尋大幅提升 10-50 倍。
4. 資料庫極致壓縮與容錯機制
 - SQL View 聚合：利用 GROUP_CONCAT 在底層將同車款多個 TPMS 規格完美串接。
 - 網路退避策略：導入 urllib3 Retry 機制，遇 HTTP 429 限制自動退避等待。

Thank you!