



橙的電子：自動化資料 工程與爬蟲系統

實習成果發表 — 打造具備自我修復
與動態渲染能力的高效能數據流



● 靜態爬蟲與 API 攔截 (Protocol-level Scraping)


- **核心優勢:** 最輕量、速度最快。
- **技術原理:** 不開啟瀏覽器，直接發送 HTTP 請求，攔截底層 HTML 或 JSON。
- **實作專案:** Interpneu 爬蟲。



● 動態渲染爬蟲 (Browser Automation)

- **應用場景:** 專解動態生成的 SPA 網頁（如 React/Vue 架構）。
- **技術原理:** 啟動無頭瀏覽器，模擬真人捲動、點擊與等待等操作行為。
- **實作專案:** AutoBild 爬蟲。

Interpneu 架構設計：極速底層 API 攔截



透過直接呼叫 API 1 (取得車型 HSN/TSN) 與 API 2 (深度取得感測器詳細資訊)，系統完全省略了網頁渲染的時間成本，達成高通量數據擷取。

Interpneu 自動化運作生命週期

① 啟動與週期檢查

- 自動安裝缺失套件。
- 智慧判斷：7 天未更新則全面清空舊紀錄；否則載入 JSON 斷點繼續進度。



② 資料庫與導航

- 連接 SQLite，建立 SQL View (設定合併邏輯)。
- 依序展開：品牌 ➡ 車系 ➡ 型號 ➡ 年份新到舊。



③ 深度抓取與聚合

- 呼叫 API 1 取得車型 (HSN/TSN)。
- 判斷是否有 OE 原廠感測器。若有，呼叫 API 2 取得詳細資訊並解析字串 (廠商/頻率/日期)。



④ 寫入與安全防護

- 攔截 Ctrl+C 中斷，觸發緊急防護。
- 暫存滿 80 筆自動批次寫入 (REPLACE INTO)。
- 強制寫入殘留資料，保留當前斷點，安全退出。



AutoBild 的動態挑戰：突破現代網頁防護



防護彈窗

Cookie 彈窗與合規阻擋機制，導致傳統爬蟲卡死。



透過非同步無頭瀏覽器精準定位 iframe，模擬點擊同意。



延遲載入 (Lazy Loading)

網頁資料非一次性給齊，依賴使用者滾動才動態生成。



注入 `window.scrollTo` 腳本，強制網頁渲染尚未載入的動態資料。



隱藏 DOM 元素

車系與車款變體收合在 UI 互動層內。



模擬真人 DOM 操作，自動點擊介面按鈕，暴力展開所有隱藏選項。

AutoBild 執行管線與核心技術

① 啟動與智慧接續

- 7 日完工檢查機制：過期則清空全新掃描；中斷則載入斷點接續。

② 動態渲染與自動化

- 啟動無頭瀏覽器 (Playwright)，模擬真實用戶 User-Agent。
- 操作 DOM 元素，展開隱藏車系。

③ 深度資料攔截 (技術核心)

- 設置背景監聽器 (context.on)。
- 直接攔截含有 HSN/TSN 的動態 API JSON 回應，徹底取代低效的 HTML 解析。
- 德文 → 中文多國語音翻譯。

④ 防護與永久保存

- 超時與中斷防護機制。
- 批次寫入資料庫，緊急安全存檔後匯出。

AutoBild car_catalog 數據產出

Database Structure Browse Data Edit F									
Table: car_catalog Filter in any column									
	Brand	Model	Category	Fuel_Type	Type	Start_Year	End_Year	HSN_TSN	
	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter	
1	XPENG	P7Plus	高背掀背車	電力	P7• AWD Performance seit 01/2028	2028	至今	N/A	
2	XPENG	P7Plus	高背掀背車	電力	P7• RWD Long Range seit 01/2028	2028	至今	N/A	
3	XPENG	P7Plus	高背掀背車	電力	P7• RWD Standard Range seit 01/2028	2028	至今	N/A	
4	WIESMANN	Wiesmann OT MF4	雙門跑車	汽油	OT MF4	2003	2018	N/A	
5	WIESMANN	Wiesmann OT MF4	雙門跑車	汽油	OT MF4 SMG	2003	2018	N/A	
6	WIESMANN	Wiesmann Roadster M7S	敞篷跑車	汽油	Roadster M7S	1983	2011	N/A	
7	WIESMANN	Wiesmann Roadster M74	敞篷跑車	汽油	Roadster M74	2010	2018	N/A	
8	WIESMANN	Wiesmann Roadster M74	敞篷跑車	汽油	Roadster M74 Sportautomatic	2010	2018	N/A	
9	WIESMANN	Wiesmann Roadster M74	敞篷跑車	汽油	Roadster M74-S	2010	2018	N/A	
10	WIESMANN	Wiesmann Roadster M7S	敞篷跑車	汽油	Roadster M74-S DRG	2010	2018	N/A	
11	WIESMANN	Wiesmann Roadster M70	敞篷跑車	汽油	Roadster M7S SMG	2010	2018	N/A	
12	VW	Amarok	皮卡	柴油	Amarok 2.0 BITDI	2010	至今	N/A	
13	VW	Amarok	皮卡	柴油	Amarok 3.0 BITDI, Advantage	2010	至今	N/A	
14	VW	Amarok	皮卡	柴油	Amarok 3.0 BITDI, Atacama	2010	至今	N/A	
15	VW	Amarok	皮卡	柴油	Amarok 2.0 BITDI, Dark Label	2010	至今	N/A	
16	VW	Amarok	皮卡	柴油	Amarok 3.0 BITDI, Highline	2010	至今	N/A	
17	VW	Amarok	皮卡	柴油	Amarok 3.0 BITDI, Trendline	2010	至今	N/A	
18	VW	Amarok	皮卡	柴油	Amarok 2.0 BITDI, Ultimate	2010	至今	N/A	
19	VW	Amarok	皮卡	柴油	Amarok 3.0 BITDI 4MOTION	2010	至今	N/A	
20	VW	Amarok	皮卡	柴油	Amarok 3.0 BITDI 4MOTION, Advantage	2010	至今	N/A	



多樣化車型覆蓋

成功抓取 XPENG (小鵬)、WIESMANN (威茲曼)、VW (福斯) 等跨品牌資料。



變體資料完整提取

如 VW Amarok 系列中，完美分離出 Advantage, Atacama, Dark Label, Highline 等多達數十種細部子型號。



欄位正規化

將動態抓取到的燃料別 (Fuel_Type)、車身型式 (Category)、年份區間 (Start/End Year) 統一正規化，建立高質量零件目錄基礎。

本地到雲端的進化：GitHub 架構部署




本地端開發與測試
(Local Execution)




OrangeInterpneu

橙的電子胎壓資料抓取專案。




OrangeAutobild

德國 AutoBild 汽車型錄爬蟲系統。



將單機版腳本重構成為具備版控、模組化且適合雲端部署的企業級微型專案。

雲端自動化引擎 (CI/CD Pipeline)



Partslink24 動態導航邏輯



Partslink24 爬蟲技術問題與改進方案

Partslink24 技術挑戰

- **語言與術語多樣性**：德語環境與 TPMS 術語缺乏統一 (如 BMW: RDC, VAG: Sensor für Reifendruck)，需專屬檢索邏輯。
- **前端動態渲染防護**：基於 React SPA 架構與嚴密 Cookie 彈窗阻擋，傳統靜態爬蟲完全失效。
- **異構目錄與搜尋限制**：各車廠導覽邏輯各異 (表格定位 vs. 層級點擊)，特定層級動態隱藏搜尋框。
- **資料解析與雜訊過濾**：假陽性干擾及間接式 TPMS 無實體零件，易致誤判與雜訊。
- **長時間運行穩定性**：Playwright 長時運行易引發崩潰，需設計容錯與斷點續爬機制。

改進與解決方案

- **建立關鍵字資料庫 (Keyword Mapping)**：利用獨立 JSON 定義各品牌檢索規則與正負向表列，提升擴充性。
- **無頭瀏覽器隱身防護 (Stealth Mode)**：導入 Playwright 動態操作，抹除 WebDriver 指紋以規避自動化偵測。
- **API 攔截取代 DOM 解析**：直接攔截底層 REST API 回應獲取結構化 JSON，大幅提升執行速度。
- **資料庫壓縮與容錯機制**：利用 SQL View 聚合資料，並導入 Retry 機制應對網路請求限制。

未來展望與實習總結



完成爬蟲與資料清洗 (Completed Crawler & Data Cleaning)

成功完成 Partslink24 爬蟲程式開發，並進行初步資料庫清洗，建立高品質資料基礎。



資料整合與優化 (Data Integration & Optimization)

將各大網站與現有資料庫合併，利用統一的 HSN/TSN 進行優化，顯著減少資料庫大小並降低搜索負擔。



實習總結 (Internship Summary)

通過此專案，深入掌握現代網頁爬蟲技術與數據處理流程，為公司建立穩定、自動化的市場數據後盾。

